


pca

L'analyse en composantes principales (ACP) est une technique statistique utilisée en analyse multivariée pour réduire la dimensionnalité des données tout en préservant autant d'informations que possible. Elle vise à transformer un ensemble de variables (qui peuvent être corrélées entre elles) en un nouvel ensemble de variables non corrélées appelées composantes principales. Les composantes principales sont ordonnées par ordre d'importance, de sorte que la première composante principale explique autant de variance que possible dans les données, la deuxième explique la variance restante non expliquée par la première, et ainsi de suite.



L'objectif de l'ACP est de simplifier la structure des données tout en préservant l'essentiel de l'information contenue dans celles-ci. Cela peut être utile dans divers domaines, notamment l'analyse des données, la visualisation des données, la réduction du bruit dans les données, la détection des tendances et des modèles cachés, et bien d'autres.

Le processus de réalisation de l'ACP implique généralement les étapes suivantes :

1. Standardisation des données : Les données sont généralement standardisées en soustrayant la moyenne de chaque variable et en divisant par l'écart-type. Cela permet de mettre toutes les variables à la même échelle.
2. Calcul de la matrice de covariance : On calcule la matrice de covariance des variables d'origine. Cette matrice indique comment les variables sont corrélées les unes aux autres.

3. Calcul des composantes principales : On trouve les vecteurs propres (ou composantes principales) de la matrice de covariance. Ces vecteurs propres représentent les directions dans lesquelles les données varient le plus.
4. Projection des données : Les données sont projetées sur les composantes principales pour obtenir de nouvelles variables non corrélées.
5. Sélection des composantes principales : On peut choisir de conserver un certain nombre de composantes principales en fonction de l'importance de la variance expliquée.

L'ACP est largement utilisée en statistiques, en analyse de données, en sciences sociales, en sciences naturelles et dans de nombreux autres domaines pour explorer et réduire la complexité des données multidimensionnelles. Elle permet également de visualiser les données de manière plus concise en réduisant le nombre de dimensions, ce qui facilite leur interprétation et leur analyse.